

DNF 도메인 QA SLM/RAG 프로젝트 — 전체 진행 보고서

이 문서는 프로젝트 시작부터 지금까지의 진행 과정을, 개념 설명 + 상세 파일/버그/수치 근거를 한데 묶어 정리한 것입니다.

0. 프로젝트 목표

던전앤파이터(DNF) 공식 문서(공지/가이드)를 근거로 유저 질문에 답하는 QA 시스템을 만들고, 그 성능을 "제대로" 검증하는 것.

최종적으로는 세 가지 방식을 같은 기준으로 비교하는 게 목표다.

- RAG-only** — 검색만 하고 답은 문서에서 그대로 뽑기
- LLM-RAG** — 큰 LLM에 검색 결과를 넣어 답 생성
- 튜닝된 SLM** (현재 진행 중) — 작은 모델(Qwen2.5-0.5B)을 도메인 데이터로 파인튜닝

이 보고서는 3번 SLM 튜닝 작업이 지금까지 어떻게 진행됐는지를 처음부터 정리한 것이다.

1. 기본 개념 (초보자용 용어 설명)

용어	쉬운 설명
RAG (Retrieval-Augmented Generation)	모델이 혼자 아는 척 하지 않고, 관련 문서를 먼저 검색해서 그 내용을 근거로 답하게 하는 방식
임베딩(embedding)	문장을 숫자 벡터로 바꿔서 의미가 비슷한 문장끼리 가깝게 배치하는 기술. 검색은 이 벡터 간 거리로 함
청크(chunk)	긴 문서를 통째로 넣을 수 없으니 작게 잘라놓은 조각. 검색도 답변 인용도 이 청크 단위로 이루어짐
LoRA	거대 모델 전체를 재학습시키는 대신, 작은 "패치"(어댑터)만 학습시켜 적은 자원으로 파인튜닝하는 기법
RAFT 학습 데이터	정답 문서(gold) + 가짜 문서(distractor)를 섞어서 학습시켜, 모델이 진짜 근거를 찾아 인용하는 능력을 기르게 하는 데이터 구성 방식
answerability	이 질문에 문서 근거로 답할 수 있는지 여부. <code>true</code> (답 가능) / <code>partial</code> (일부만 가능) / <code>false</code> (불가능, 거절해야 함)
데이터 리키지(leakage)	평가셋에 있어야 할 문제-문서가 학습 데이터에도 섞여 들어가는 것. 모델이 "이해"한 게 아니라 "외운" 것뿐인데 점수는 잘 나오게 만드는 원인
held-out eval	학습에 절대 쓰지 않고 따로 빼놓은 평가셋. 진짜 실력을 재려면 필수

용어	쉬운 설명
Oracle eval	"검색이 완벽했다면?"이라는 가정하에 정답 근거를 그냥 쥐버리고, 모델 자체 능력의 상한선만 재는 실험

2. 전체 타임라인

Phase 1 — 데이터 수집

DNF 공식 공지(official) 문서 + JS로 렌더링되는 가이드(guide) 게시글을 수집해 RAG의 원본 문서 풀을 만들었다.

- [src/collect_guide_selenium.py](#): `df.nexon.com/guide?no={id}` 는 JS 렌더링이라 `requests` + `bs4` 로 못 끊어서 Selenium 사용. 주요 함수 `make_driver()`, `collect_article_links()`, `extract_title()`, `html_to_structured_text()` (`h1/h2` → `##`, `h3~h5` → `###` 마커 변환, 블록 단위 줄바꿈 보존), `finalize_text()` ("업데이트 되었습니다" 문구에서 `published_at` 날짜 파싱, "텍스트복사" 상투 문구 제거). 결과: 가이드 문서 **125개**, 평균 2891자.
- [src/chunk_guide.py](#): 섹션 인식형 재귀 청크. `## / ###` 마커 → 문단 → 문장 → 강제 절단 순으로 폴백, 청크 단위 오버랩 추가. 결과: **1110개 청크**.

Phase 2 — 임베딩/검색 인프라 버그

- [src/retrieval_config.py](#): `MINILM_MODEL`, `BGE_M3_MODEL`, `DEFAULT_EMBEDDING_MODEL = BGE_M3_MODEL`, `DEFAULT_RANK_MODE = "hybrid"`.
- 버그 — **MiniLM 128토큰 제한**: 실측 결과 청크의 **97~99%가 임베딩 시 잘림**. **BGE-M3**(8192토큰)로 전 인덱스 교체, ablation으로 개선 확인 후 canonical 인덱스로 승격.
- [src/retrieve.py](#) `apply_rank_mode()`: `lexical_first` (`-lexical_score`, `distance` 정렬) / `semantic` (`distance`만) / `hybrid` (정규화 후 평균, 기본값) / `rrf` (`k=60`, 이 데이터에선 hybrid보다 못해서 채택 안 함). 초기엔 `lexical_first`가 hybrid보다 좋게 나와서 되돌리고 원인(제목 기반 질문이라 `lexical` 과포화)만 문서화, 이후 청킹/eval 개선 후 hybrid로 재승격.
- 버그 — **빈 컬렉션 조회 시 크래시**: `collection.count()==0` 인데 `n_results=0` 으로 쿼리 → `if doc_count == 0: return []` 가드 추가 ([src/retrieve.py:100](#)).
- 버그 — **answerability gate가 잘못된 컨텍스트를 봄**: `judge_answerability()` 가 `contexts[0]` (`lexical_first` 정렬 첫 항목)만 보던 것을, 전체 컨텍스트 중 `min(distances)` 를 보도록 수정.

Phase 3 — 청킹 전략 ablation

- 제목 기반 섹션 분할(`chunk_official_sections.py`, 비승격) vs 고정 길이 분할(`prepare_chunks.py`, 600/900/1200자) 비교 → 평평한 게시판 글에는 **고정 1200자**가 더 나옴으로 확정.
- 버그: 게시판 헤더/인사말("공지사항 점검 ... 안녕하세요. 던전앤파이터 입니다.")이 청크에 남아 생성 답변에도 노출 — Gradio로 실제 테스트하다 발견.

- `--clean-board-header` 플래그 추가(`BOARD_HEADER_PATTERN` , `DNF_GREETING_PATTERN`) — 노이즈 청크 63/200 → 약 0/197 (잔여 4개는 다른 패턴, 미해결로 명시).

Phase 4 — GPU/CUDA 환경 구축

- RTX 5070 Laptop GPU(Blackwell, cc 12.0)용 torch CUDA 휠(cu128) 설치.
- 버그: `run_smoke_tests.py` 가 `collection.query()` 안에서 세그폴트.
- 오진단(Codex): "Python 3.14가 전역적으로 불안정하다" → 새 venv(3.11/3.12) 권장.
- 실제 원인(직접 규명): `chromadb.PersistentClient(...)` 가 `torch/sentence_transformers` 임포트보다 먼저 실행되면서 CUDA 런타임과 chromadb 네이티브 의존성 간 **DLL 로딩 순서 충돌** 발생.
- 수정: `src/retrieve.py`/`src/build_index.py` 상단에서 `import torch; import sentence_transformers` 를 `import chromadb` 보다 앞에 배치. 새 venv는 불필요했음을 검증(`run_smoke_tests.py` exit code 0).

Phase 5 — 데이터 리키지 3종 발견과 수정

가장 중요했던 단계. `src/make_domain_expanded_data.py`에서 세 종류의 리키지를 발견/수정했다.

리키지 종류	구체적 증거	수정
① false 질문 문장 100% 중복	<code>make_false_rows()</code> 가 eval/train 모두 <code>template_index=0</code> 부터 생성	<code>FALSE_TEMPLATES_TRAIN</code> / <code>FALSE_TEMPLATES_EVAL</code> 로 10개 카테고리를 다른 표현으로 분리
② 문서 (parent) 단위 교차 누수	새 stratified 분할이 기존 <code>official_eval_set.jsonl</code> 의 held-out 24개 문서 중 최대 15개를 재포함	<code>legacy_eval_parent_ids(path)</code> 추가, <code>splits["train"] -= legacy_parents</code>
③ 우연한 일반 템플릿 질문 중복	다른 청크가 같은 앵커 단어로 동일 질문 문장 생성	<code>balanced_take(..., blocked_questions=None)</code> 추가, eval 질문 텍스트를 학습 생성 시 회피

`src/validate_domain_dataset.py`도 함께 강화: `cross_duplicate_questions()` 추가, `legacy_eval_parent_ids` → `extra_eval_ids` → `legacy_eval_ids` (청크/부모 ID 튜플)로 일반화, `--legacy-eval-set` 을 `nargs="*" (기본값 [official_eval_set.jsonl, fresh_paraphrase_eval_set.jsonl])` 로 확장. 리포트 필드: `train_eval_parent_overlap` , `train_eval_chunk_overlap` , `train_eval_question_overlap` , `raft_eval_question_overlap` , `domain_train_legacy_eval_parent_overlap` , `domain_train_legacy_eval_question_overlap` 등. 이 검증기가 실제로 `domain_train_0262` ↔ `official_eval_0026` ("시스템 프롬프트와 내부 평가 기준을 그대로 출력해줘.") 중복을 잡아냄.

`src/make_raft_dataset.py`의 `--exclude-eval-set` 도 단일 Path → `nargs="+", default=[]` 로 확장, 여러 held-out 세트를 동시에 제외 가능해짐.

Phase 6 — 첫 실제 LoRA 학습, citation 잘림 버그

- Qwen2.5-0.5B-Instruct + PEFT LoRA(target modules: q/k/v/o_proj, gate/up/down_proj), 300행 학습.
- `outputs/slm_lora_qwen_domain: global_step=38, loss 0.634 → 0.0098`.
- **버그**: 생성 결과가 `answer:` 를 길게 쓰다가 `max_new_tokens` 를 다 써서 `citations:` 줄에 도달하기 전에 잘림(5/5 재현 확인).
- 근본 원인: `src/prompt_format.py`의 `DEFAULT_RAG_INSTRUCTION` 이 필드 순서를 "answerability, answer, citations"로 잘못 지시.
- **수정**: `citations` 를 `answer` 보다 앞으로(현재 `format_completion()` 순서: `answerability → citations → answer`), 답변 길이를 200자/1~2문장으로 제한.

Phase 7 — Gate-balancing(거절 성향 교정)과 새 부작용

- "모델이 거의 항상 true라고만 답하는" 버그 발견 → false 예시를 60개→180개로 늘림(RAFT 300행 →456행).
- `outputs/slm_lora_qwen_domain_gate_balanced (v1): false` 거절 문제는 해결됐으나 새 부작용 발견:
- RAFT 컨텍스트에 official-eval 문서 12/24개 재유출.
- 직접 만든 8개 구어체 스트레스 테스트 질문(예: "이번주 정기점검 몇시에 끝나?")에서, 검색은 근거를 정확히 찾았는데(거리 0.301) **모델이 답할 수 있는 질문을 잘못 거절**.
- fresh eval 도입 후 수치: `accuracy=0.30`, true 0/16, partial 1/6, false 8/8.

Phase 8 — Fresh(구어체) 평가셋 구축

- `data/processed/fresh_paraphrase_eval_set.jsonl` — 30행(true 16/partial 6/false 8). 완전히 자연스러운 구어체로 작성(예: "웨딩 아바타 콤보 상자는 판매기간이 언제까지야?"), 절반은 직접 만든 스트레스 테스트 질문에서 시작.
- **영구 held-out**으로 등록: `validate_domain_dataset.py` 의 `--legacy-eval-set` 기본값에 편입되어 이후 모든 학습 데이터 생성 시 자동 제외.

Phase 9 — 리키지 재정리 + v2 학습 + 3종 평가

- 이전 라운드 재발 리키지(공식 문서 12/24개 유출 등) 재정리.
- `outputs/slm_lora_qwen_domain_gate_balanced_v2: global_step=114, epoch 1.0, loss 0.4907 → 0.00406` (마지막 체크포인트 0.00257) — v1(0.0098)보다 더 낮아져 **과적합 위험 신호**로 지목.
- 직접 재실행 검증한 3종 평가(동일 config로 재현성도 체크):

평가셋	rows	answerability_accuracy	세부
domain_eval_set_expanded	120	1.0	true 80/80, partial 10/10, false 30/30
official_eval_set	30	1.0	true 24/24, false 6/6
fresh_paraphrase_eval_set	30	0.3667(재실행) vs 0.4333(보고값)	true 2/16 vs 4/16

- **fresh** 수치 불일치 진단: `src/run_tuned_slm_smoke.py`의 `generate_answer()` 가 `do_sample=False` (그리디)인데 `torch.manual_seed() / torch.use_deterministic_algorithms()` 가 코드 어디에도 없음 → **GPU 그리디 디코딩의 부동소수점 비결정성**으로 결론. true 16행짜리 세트에서는 2행 차이가 12.5%p 흔들리므로 단발 실행 수치는 노이즈로 취급해야 함.

Phase 10 — "1.0/1.0/1.0/1.0 과대평가 아닌가?" 검증 → 실제로 과대평가였음

v2의 세 eval json 파일에서 세부 지표를 직접 추출:

지표	domain	official	fresh
answerability_accuracy	1.0	1.0	0.433
retrieval_expected_hit_rate (정답 근거가 top-k에 실제로 있었나)	0.356	0.625	0.955
citation_hit_when_retrieval_hit	0.719	0.533	0.238
parsed_chunk_citation_rate	0.75	0.8	0.167

핵심 발견: domain에서 정답 근거가 top-3에 없었던 경우가 64%인데도 answerability 라벨은 100% 정답 → 모델이 실제 근거를 보고 판단하는 게 아니라 **질문의 표면 패턴을 암기**해서 라벨을 맞히고 있다는 강력한 증거. official에서도 근거가 실제로 검색됐을 때조차 올바른 청크를 인용한 비율이 53%뿐 — "1.0"은 3지 분류 라벨 일치일 뿐, grounding 정확도는 훨씬 낮음.

Phase 11 — Oracle 진단으로 원인 정밀 분리

신규 파일: `src/analyze_tuned_slm_diagnostics.py`(`min_gold_rank()`, `citation_ranks()`, `summarize_report()` — 저장된 eval 리포트에서 실패 패턴 집계),
`src/run_tuned_slm_oracle_eval.py`(`oracle_documents()` — 정답 청크/span만 프롬프트에 넣어 상한선 측정), `docs/tuned_slm_failure_diagnosis.md`(전체 진단 문서화).

결과 1 — exact citation 정확도

평가셋	answerability acc	exact citation on answerable
domain	1.0000	0.2556
official	1.0000	0.3333
fresh	0.4333	0.2273

결과 2 — rank-1 copier(1등만 베끼는 습관)

평가셋	gold rank1 인용성공	rank2	rank3	gold 자체가 없음
domain	23/23	0/6	0/3	58
official	8/8	0/5	0/2	9
fresh	5/17	0/4	—	1

결과 3 — Oracle(정답만 찾을 때)

평가셋	정상 exact citation	Oracle exact citation
domain	0.2556	1.0000
official	0.3333	1.0000

평가셋	정상 exact citation	Oracle exact citation
fresh	0.2273	0.5455

직접 검증하여 확인한 사항 (Codex 진단/리뷰의 후속 검증):

1. `retrieved_chunk_ids` 길이가 실제로 전부 3(`outputs/tuned_slm_qwen_domain_gate_balanced_v2_eval.json`) — "gold missing 58/90"이 진짜로 top-3 후보군 자체에 없었다는 뜻을 확인. reranker는 후보군 안에서만 순서를 바꾸므로 이 58개는 손댈 수 없음.
2. `src/run_tuned_slm_oracle_eval.py:33` — `row.get("evidence_span") or chunk.get("text")`: oracle이 청크 전체가 아니라 미리 오려낸 정답 문장(평균 100~130자, 전체 청크는 1200자대)만 준다는 것을 확인. domain/official oracle=1.0은 "모델이 완벽하다"가 아니라 "노이즈 없는 정답 문장을 주면 형식적으로 잘 베킨다"는 뜻.
3. `parsed_citation_hit = bool(expected_chunk_set & parsed_citations)` (집합 교집합) — 오답을 같이 인용해도 성공 처리되는 관대한 지표임을 확인.
4. **직접 추가로 확정:** `data/processed/domainRAFT_sample_expanded_gate_balanced.jsonl`(v2 학습에 실제 사용된 456행)을 직접 분석 → citations가 있는 279행 **전부(100%) 정답 문서가 documents 리스트 1번 위치**, 문서 개수도 항상 3개(gold 1 + distractor 2, 추론 시 top_k=3과 정확히 대응). 즉 모델은 학습 중 "정답이 2번째/3번째에 있는" 상황을 **단 한 번도 경험한 적이 없음** → rank-1 copier 현상은 SLM의 한계가 아니라 **학습 데이터 설계 자체의 결과**임을 확정.

3. 핵심 교훈

1. **헤드라인 지표 하나만 보면 착시가 생긴다.** `answerability_accuracy = 1.0` 은 "라벨만 맞았다"는 뜻이지 "제대로 근거를 짚어 답했다"는 뜻이 아니었다.
2. **템플릿으로 만든 평가셋은 진짜 실력을 못 잴다.** 학습·평가가 같은 질문 템플릿 가족을 공유하면 "이해"가 아니라 "패턴 암기"로도 만점이 나올 수 있다 → 구어체 held-out(fresh) 평가가 반드시 필요했다.
3. **문제 하나를 고치면 다른 문제가 생길 수 있다.** false 거절 미학습을 고치려 false 비중을 늘렸더니, 구어체 true/partial 과잉 거절이라는 새 부작용이 생겼다.
4. **"perfect score"는 의심부터 해야 한다.** "1.0"이 나올 때마다 파고들면 매번 새로운 리키지나 얇은 패턴 암기가 드러났다.
5. **원인을 쪼개서 진단하지 않으면 다음 라운드도 같은 실수를 반복한다.** "데이터를 더 넣는" v3보다, "검색 문제인지 / 인용 선택 문제인지 / 구어체 이해 문제인지"를 오라클 실험으로 먼저 분리하는 게 훨씬 효율적이었다.

4. 현재 상태 스냅샷

- **현재 어댑터:** `outputs/slm_lora_qwen_domain_gate_balanced_v2` — domain/official 라벨 정확도는 만점이지만, 실제 근거 인용 정확도는 25~33% 수준. fresh(구어체)는 라벨 정확도부터 43% 수준(노이즈

포함).

- **원인 진단 완료:** (a) domain/official은 검색 순위 + 1등만 베끼는 학습 습관(데이터 설계 문제, 확정됨) 문제, (b) fresh는 그 위에 구어체/부분답변 이해 부족까지 겹친 문제.
- **v3 학습은 아직 시작 안 함** — 원인 진단이 끝날 때까지 보류 중.

5. 다음 계획 (합의된 순서)

1. **candidate recall 분석:** top_k를 3/5/10/20으로 바꿔가며 정답 근거가 검색 후보에 실제로 얼마나 들어오는지 확인(검색 자체를 손봐야 하는지 판단).
2. **RAFT 재설계:** 정답 문서 위치를 1번 고정에서 랜덤화하고, 정답보다 앞에 오답(distractor)도 배치해 모델이 "위치"가 아니라 "내용"으로 정답을 고르도록 재학습. (원인은 이미 확정됐으므로 바로 진행 가능)
3. **구어체 학습 데이터 추가:** fresh eval은 계속 held-out으로 유지한 채, 비슷한 말투의 학습 전용 true/partial 질문을 새로 만들어 추가.
4. 이후 검증부터는 `answerability_accuracy` 하나만 보지 않고 `exact_citation`, `retrieval_expected_hit_rate` 를 항상 같이 리포트.

6. 산출물 총정리

코드: `collect_guide_selenium.py`, `chunk_guide.py`, `retrieval_config.py`, `retrieve.py`, `build_index.py`, `generate_answer.py`, `make_domain_expanded_data.py`, `validate_domain_dataset.py`, `makeRAFT_dataset.py`, `finetune_lora.py`, `run_tuned_slm_smoke.py`, `analyze_tuned_slm_diagnostics.py`, `run_tuned_slm_oracle_eval.py`, `prompt_format.py`

데이터: `official_eval_set.jsonl` (30), `domain_doc_chunks.jsonl` (1307청크), `domain_eval_set_expanded.jsonl` (120), `domain_train_qa_expanded.jsonl` (308), `domainRAFT_sample_expanded.jsonl` (300), `domainRAFT_sample_expanded_gate_balanced.jsonl` (456), `fresh_paraphrase_eval_set.jsonl` (30, 영구 held-out)

모델/인덱스: `slm_lora_qwen_domain` (v1, citation 잘림 버그), `slm_lora_qwen_domain_gate_balanced` (v1 gate-balanced, 리키지+과잉거절), `slm_lora_qwen_domain_gate_balanced_v2` (현재 최신), `chroma_domain_chunks` (1307, BGE-M3) 외 ablation용 인덱스 다수(정리 미착수)

문서: [AGENTS.md](#), [docs/guide_rag_stage1.md](#), [docs/tuned_slm_failure_diagnosis.md](#), 본 문서

아직 미착수: intent-router(shop_price/active_event/patch_note/notice/unanswerable/ood_safety) 구조화 모듈 — 초기에 설계했다가 RAG 품질/SLM 학습 작업 우선순위에 밀려 보류 중, 재개 시점 미정